

Statistiques : compléments théoriques

Juste Raimbault ¹

2025-2026

¹LaSTIG, IGN-ENSG-UGE

ENSG
Géomatique

ÉCOLE NATIONALE
DES SCIENCES
GÉOGRAPHIQUES

Estimateur statistique

Propriétés asymptotiques des estimateurs

Décomposition biais-variance

Intervalles de confiance et bootstrap

Estimateur statistique

- **Paramètre ou propriété de la population (θ):**
caractéristique fixe et inconnue de la population (représentée par une variable aléatoire X avec loi sous-jacente): paramètre de la loi μ, σ^2, β , moments, etc.
- **Echantillon:** observations (X_1, \dots, X_n) indépendantes et identiquement distribuées.

Definition

Un **estimateur** ($\hat{\theta}$) est une fonction mesurable des observations X_i , utilisée pour calculer une approximation de θ .

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

→ l'échantillonnage X_i est aléatoire, donc $\hat{\theta}$ est une **Variable Aléatoire**.

Estimateur ($\hat{\theta}$)

- La **formule** de calcul
- Une **Variable aléatoire** (avec une distribution d'échantillonnage)
- **Exemple:** $\bar{X} = \frac{1}{n} \sum X_i$

Estimate ($\hat{\theta}$)

- La **valeur** spécifique calculée sur un échantillon observé
- **Nombre fixe**
- Tests et intervalles de confiance associés

Un estimateur $\hat{\Theta}$ est évalué sur les propriétés de sa distribution d'échantillonnage par rapport au vrai paramètre θ .

- **Biais** : estimation correcte en moyenne ?
 - $\text{Bias}(\hat{\Theta}) = \mathbb{E}[\hat{\Theta}] - \theta$
 - Non-biaisé si $\mathbb{E}[\hat{\Theta}] = \theta$.
- **Efficacité (Variance)** : quelles fluctuations entre différents échantillonnages ?
 - $\text{Var}(\hat{\Theta}) = \mathbb{E} \left[(\hat{\Theta} - \mathbb{E}[\hat{\Theta}])^2 \right]$
 - Une variance faible est préférée.
- **Convergence** : comportement en fonction de la taille de l'échantillon n (cf. loi des grands nombres et Théorème Central Limite)
 - $\hat{\Theta} \xrightarrow{p} \theta$ avec $n \rightarrow \infty$

- **Hypothèses:** Échantillon i.i.d. X_1, \dots, X_n avec $\mathbb{E}[X] = \mu$ et $\text{Var}(X) = \sigma^2$.

Estimateur Biaisé

$$S_b^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$\mathbb{E}[S_b^2] = \frac{n-1}{n} \sigma^2$$

→ sous-estimation de σ^2

Estimateur Non Biaisé (correction de Bessel)

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Propriétés asymptotiques des estimateurs

Soit $(X_i)_{i \geq 1}$ des Variables Aléatoires indépendantes et identiquement distribuées (i.i.d.) telles que $\mathbb{E}[X_i] = \mu < \infty$.

La moyenne empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ converge **presque sûrement** vers μ :

$$\mathbb{P} \left(\lim_{n \rightarrow \infty} \bar{X}_n = \mu \right) = 1$$

- **Hypothèses:** X_1, \dots, X_n i.i.d. avec $\mathbb{E}[X_i] = \mu$ et **variance finie** $\text{Var}(X_i) = \sigma^2 < \infty$.
- Soit $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ la moyenne d'échantillon.

Loi Faible des Grands Nombres

La moyenne d'échantillon \bar{X}_n converge en probabilité vers l'espérance μ .

$$\forall \epsilon > 0, \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

Remarque : convergence p.s. \implies convergence en probabilité

Inégalité de Tchebychev

Pour toute V.A. Z avec $\mathbb{E}[Z] = \mu_Z$ et $\text{Var}(Z) = \sigma_Z^2$ finie, $\forall \epsilon > 0$:

$$P(|Z - \mu_Z| \geq \epsilon) \leq \frac{\text{Var}(Z)}{\epsilon^2}$$

→ application à $Z = \bar{X}_n$: comme $\text{Var}(\bar{X}_n) = \sigma^2/n$

$$P(|\bar{X}_n - \mu| \geq \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2} = \frac{\sigma^2/n}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

d'où la LFGN par le théorème des gendarmes.

- **Principe:** La distribution de la moyenne de V.A. i.i.d. de variance finie σ^2 tend vers une **Loi Normale**, quelles que soient leurs distributions initiales.

Théorème de la Limite Centrale

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} \mathcal{N}(0, 1) \quad \text{quand } n \rightarrow \infty$$

→ permet l'inférence statistique (tests d'hypothèses, intervalles de confiance) quelle que soit la distribution des données d'origine.

Moment d'ordre k : $m_k = \mathbb{E}[X^k]$ estimé par $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

Convergence des Moments (conséquence de la LFGN)

Si m_k existe et est fini, alors son estimateur empirique \hat{m}_k converge en probabilité vers lui :

$$\hat{m}_k \xrightarrow[n \rightarrow \infty]{P} m_k$$

- TCL approximation d'ordre 1
- termes correctifs basés sur les moments d'ordre supérieur

Formule de l'Expansion (Ordre 1)

La densité de Z_n est mieux approximée par :

$$f_{Z_n}(z) \approx \phi(z) \left[1 + \frac{\gamma_3}{6\sqrt{n}} H_3(z) + \frac{\gamma_4}{24n} H_4(z) + o\left(\frac{1}{n}\right) \right]$$

- $\phi(z)$: densité de la $\mathcal{N}(0, 1)$
- γ_3 : **Skewness** (asymétrie) de la population
- γ_4 : **Kurtosis** (excès d'aplatissement) de la population
- $H_k(z)$: Polynômes d'Hermite

→ cas avec variance infinie ? (ex: Loi de Pareto avec $\alpha \leq 2$, Loi de Cauchy)

Théorème (TCLG)

La limite d'une somme de variables i.i.d. (correctement normalisée) est une **Distribution Stable** (ou "Loi Stable de Lévy") avec un indice de stabilité $\alpha \in (0, 2]$

- **Cas 1:** $\alpha = 2 \implies$ **Loi Normale**. On retrouve le TCL standard (le seul cas où la variance est finie).
- **Cas 2:** $\alpha < 2 \implies$ Variance infinie, queues lourdes.
- **Cas 3:** $\alpha = 1 \implies$ **Loi de Cauchy** (avec $\beta = 0$).

Décomposition biais-variance

Contexte : minimisation de la MSE du modèle $\hat{f}(x)$ cherchant à approximer Y .

Décomposition de la MSE

$$\mathbb{E} \left[\left(Y - \hat{f}(x) \right)^2 \right] = \mathbf{Biais}^2 + \mathbf{Variance} + \mathbf{Bruit\ intrinsèque}$$

→ propriété sous-jacente lors de la selection de modèle et le contrôle du sur-apprentissage

En supposant $Y = f(x) + \epsilon$ avec $\mathbb{E}[\epsilon] = 0$ et $\text{Var}(\epsilon) = \sigma^2$, on obtient la décomposition :

$$\begin{aligned}\mathbb{E} \left[\left(Y - \hat{f}(x) \right)^2 \right] &= \underbrace{\left(\mathbb{E}[\hat{f}(x)] - f(x) \right)^2}_{\text{Biais}^2} \\ &+ \underbrace{\mathbb{E} \left[\left(\hat{f}(x) - \mathbb{E}[\hat{f}(x)] \right)^2 \right]}_{\text{Variance}} \\ &+ \underbrace{\mathbb{E} \left[\epsilon^2 \right]}_{\text{Bruit intrinsèque}}\end{aligned}$$

En pratique, $\mathbb{E}[\hat{f}(x)]$ correspond à l'erreur de prédiction moyenne sur l'ensemble des jeux de données possibles.

1. **Bias (Bias^2):** erreur systématique
2. **Variance ($\text{Var}(\hat{f}(x))$):** variabilité au regard des données d'entraînement
3. **Erreur intrinsèque (σ^2):** bruit non capturé par le modèle

Compromis :

- **Haute complexité** \implies faible biais, forte variance (Overfitting)
- **Basse complexité** \implies fort biais, faible variance (Underfitting)

Intervalles de confiance et bootstrap

→ approches des intervalles de confiance font des hypothèses sur la distribution

Definition

La méthode **Bootstrap** est une méthode computationnelle non-paramétrique qui utilise B nouveaux échantillons (\mathcal{D}^*) par **rééchantillonnage avec remise** des données initiales \mathcal{D} .

→ Pour chaque nouvel échantillon \mathcal{D}_b^* , calcul de la statistique $\hat{\theta}_b^*$ et utilisation de sa distribution empirique

Justification théorique

Théorème de Glivenko-Cantelli : le ré-échantillonnage préserve les propriétés asymptotiques de l'estimateur

1. **Statistique:** calcul de $\hat{\theta}$ avec \mathcal{D}
2. **Echantillon de bootstrap :** tirage de B échantillons \mathcal{D}_b^*
3. **Statistiques de bootstrap empiriques:** calcul de chaque $\hat{\theta}_b^*$
4. **IC :** distribution empirique de $\{\hat{\theta}_b^*\}$ donne l'IC, avec par exemple les quantiles pour un IC à $100(1 - \alpha)\%$:
 - tri des répliques $\hat{\theta}_{(1)}^* \leq \dots \leq \hat{\theta}_{(B)}^*$.
 - IC donné par :

$$\text{IC}_{1-\alpha} = \left[\text{Percentile}_{\alpha/2}, \text{Percentile}_{1-\alpha/2} \right]$$